BIGDATA TEAM

#W4PA: Inverted Index CLI with logging

Ungraded programming assignment

---

1. Описание задания

В этом задании вам нужно настроить логирование для консольной утилиты по работе с инвертированным индексом. Цель задания:

1. Научить настраивать логирование;
2. Научить его тестировать;

2. Инвертированный индекс (Inverted Index)

Инвертированный индекс представляет собой словарь, где ключами являются слова (термы), а значениями - списки идентификаторов документов, в которых указанный терм встречается (см. Рис. 1).

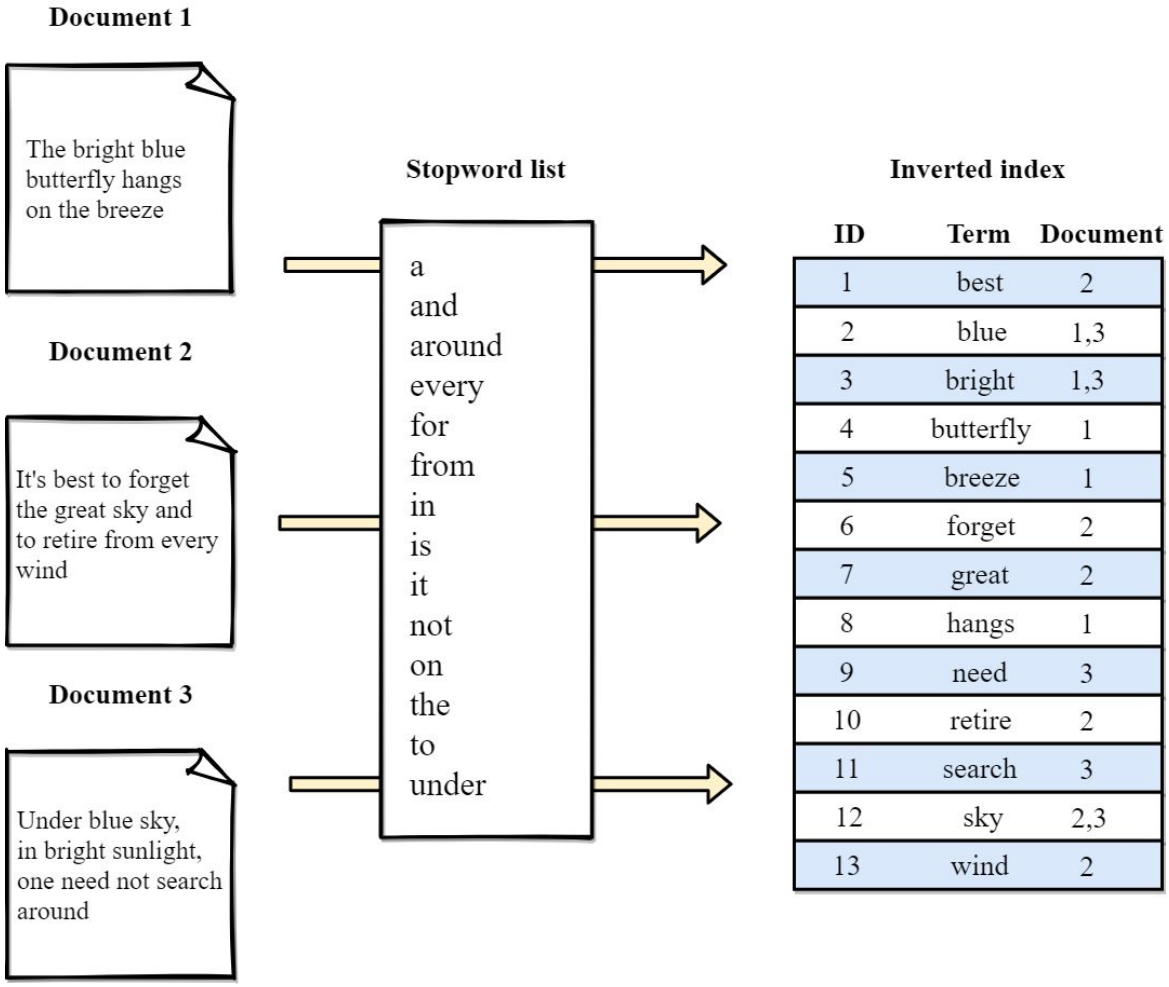

ID	Term	Document
1	best	2
2	blue	1,3
3	bright	1,3
4	butterfly	1
5	breeze	1
6	forget	2
7	great	2
8	hangs	1
9	need	3
10	retire	2
11	search	3
12	sky	2,3
13	wind	2

(Рис. 1) Инвертированный индекс

Такая структура позволяет поисковым системам найти страницы в интернете, которые могут быть релевантны пользовательскому запросу. Вам будет предоставлен датасет из документов и по этому датасету нужно построить инвертированный индекс. Консольное приложение должно предоставлять возможность:

1. Построить инвертированный индекс и сохранить его на диске используя различные стратегии (см. argparse:add_argument:choices со значением по умолчанию) - "`inverted_index.py build ...`";
2. Удалить стоп-слова при построении индекса - "`inverted_index.py build --stop-words <path> ...`";
3. Найти документы, соответствующие поисков**ым** запрос**ам**. Если в запросе указаны слова "Python" и "code", то нужно вывести только те документы, которые содержат **оба** этих слова. (см. `action='append'`) - "`inverted_index.py query --json-index <path> --query <word> [<word> ...] --query <word> [<word> ...] ...`"

3. Описание данных

3.1 Дамп Википедии

- Формат: текст
- В каждой строке находятся следующие поля, разделенные знаком табуляции:
    1. `INT` - id статьи,
    2. `STRING` - текст статьи,

Пример:

```
12	Anarchism	Anarchism is often defined as a political philosophy which holds the state to be undesirable, unnecessary, or harmful.
```

3.2 Стоп-слова

- Формат: одно стоп-слово на строчку

Пример:

```
...
wherein
whereupon
wherever
...
```

4. Задания

Prerequisites:

1. Настройка окружения: https://github.com/big-data-team/python-course
2. Датасеты: https://github.com/big-data-team/python-course#study-datasets

Возьмите за основу решение задания HW #01: Python CLI Application

С учетом примеров и лайфхаков, показанных на этой неделе:

1. Добавьте логирование в файл и stderr. Настройте логирование с помощью Python объектов logging.{Formatter,*Handler} и им подобных. Протестируйте поведение логирования с помощью pytest:caplog. Убедитесь, что тесты работают при удалении pytest.ini и удалении все опций --log из флагов для pytest.
2. Научитесь правильно считывать и сохранять ascii картинки в YAML файлах. Для вдохновения посмотрите на ascii картинки на сайте https://www.asciiart.eu/.
3. Настройте логирование с помощью YAML конфига.
4. Добавьте возможность выводить логи на экран при указании флага verbocity[1]:
    a. -v - показывать на экране лог сообщения уровня WARN+
    b. -vv - показывать на экране лог сообщения уровня INFO+
    c. -vvv (и больше) - показывать на экране лог сообщения уровня DEBUG+

Материалы для погружения:

1. https://docs.python.org/3/howto/logging.html
2. https://docs.python.org/3/library/logging.config.html
3. https://docs.python.org/3/howto/logging-cookbook.html

[1] См. action “count” для argparse